

Informe Final — Proyecto Integrador

Minería de Datos 1

Integrantes: [Nombre 1] · [Nombre 2] | Comisión: [X] | Fecha: [Completar]



1. Contexto y objetivo

El presente proyecto analiza un dataset de costos médicos de pacientes con variables demográficas, físicas y de hábitos. El objetivo es aplicar los contenidos de Minería de Datos 1 para construir un análisis de datos con decisiones justificadas, trazabilidad del proceso y comunicación clara de resultados. Las preguntas de análisis definidas son: (1) ¿Fumar es el factor que más influye en los costos médicos? (2) ¿A mayor IMC y edad, mayores costos? ¿Se potencian entre sí? (3) ¿Existen grupos diferenciados de pacientes según su perfil de riesgo? El alcance es exploratorio y no incluye modelado predictivo.

2. Dataset y calidad inicial

El dataset contiene 1363 registros y 8 columnas: age, sex, bmi, children, smoker, region y charges (variable objetivo). La inspección inicial identificó los siguientes problemas de calidad: 102 valores nulos en age (7.5%); 50 valores nulos en bmi (3.7%); 6 registros con bmi=999 (error de carga evidente); 2 registros con children=-1 (valor imposible) y 1 con children=99 (inverosímil); inconsistencias de capitalización en sex (female/Female) y smoker (yes/Yes, no/No); mezcla de abreviaciones y nombres completos en region (SE/southeast, etc.). No se detectaron filas completamente duplicadas.

Variable	Problema	Registros afectados
age	Valores nulos	102 (7.5%)
bmi	Valores nulos	50 (3.7%)
bmi	Valor erróneo (999)	6
children	Valores imposibles/inverosímiles	3
sex, smoker	Inconsistencia capitalización	Todo el dataset
region	Mezcla abreviaciones/nombres	Todo el dataset

3. Decisiones de limpieza y preparación

Cada decisión se tomó con base en evidencia observada durante la inspección. Se eliminó la columna Unnamed: 0 por ser un índice redundante sin valor analítico. Se normalizaron las variables categóricas a minúsculas y se mapearon las abreviaciones de region a nombres completos, operación que no elimina registros pero corrige la cardinalidad de las variables. Se eliminaron los registros con bmi ≥ 100 ($n=6$) por representar errores de carga no imputables: un IMC de 999 no puede estimarse a partir de la distribución real de la variable. Se eliminaron los registros con children < 0 o children > 20 ($n=3$) por el mismo criterio. Los nulos en age (102) y bmi (44 restantes tras eliminar outliers) se imputaron con la mediana, justificado por la distribución aproximadamente simétrica de ambas variables. El dataset procesado contiene 1301 registros (retención: 95.5%) y no presenta valores nulos. El registro completo de transformaciones se encuentra en logs/pipeline_log.csv.

4. Hallazgos del análisis exploratorio

La distribución de charges presenta asimetría positiva marcada (mediana ~9.300 USD, máximo ~63.000 USD), con indicios de estructura bimodal coherente con la existencia de grupos diferenciados. El hallazgo central es la diferencia de costos entre fumadores y no fumadores: los fumadores tienen un costo medio de ~32.000 USD frente a ~8.400 USD de los no fumadores, diferencia de casi 4 veces. La correlación de smoker_num con charges es $r=0.79$, la más

alta de todas las variables del dataset. La edad ($r=0.30$) y el IMC ($r=0.20$) muestran relaciones positivas moderadas con los costos. El análisis multivariado confirma que el efecto del tabaquismo sobre los costos es consistente en todas las regiones geográficas, descartando mediación regional.

5. Escalamiento y PCA

Se aplicó PCA sobre las variables age, bmi, children, smoker_num y charges, escaladas con StandardScaler (media=0, desvío=1) para neutralizar las diferencias de magnitud entre variables. Se excluyeron sex (correlación casi nula con charges) y region (categórica nominal sin orden). Las dos primeras componentes explican aproximadamente el 60-65% de la varianza total; se requieren 3 componentes para superar el 80%. PC1 está dominada por smoker_num y charges, representando el perfil de costo y riesgo por tabaquismo. PC2 captura principalmente age y bmi, representando el perfil demográfico y físico. La proyección en PC1-PC2 muestra una separación espacial clara entre fumadores y no fumadores, con el gradiente de costos alineado con PC1.

6. Conclusiones y limitaciones

El tabaquismo es el factor con mayor influencia sobre los costos médicos: los fumadores generan costos casi 4 veces superiores a los no fumadores, patrón consistente en todas las regiones. La edad y el IMC tienen efectos positivos moderados que se potencian dentro del grupo de fumadores. El PCA confirma la existencia de grupos diferenciados con el tabaquismo como eje principal de separación. Limitaciones: el análisis es exploratorio y no establece causalidad; la imputación por mediana introduce simplificación; no se dispone de datos clínicos adicionales. Mejoras futuras: clustering sobre el espacio PCA; incorporación de variables clínicas adicionales.

[REDACTED]

[REDACTED]

Repositorio GitHub: [https://github.com/\[usuario\]/PI_Mineria_Datos_1](https://github.com/[usuario]/PI_Mineria_Datos_1) | Aplicación Streamlit: [https://\[app\].streamlit.app](https://[app].streamlit.app)